



Programa Internacional de Ciencia de Datos

5ta Edición

DEMO DAY

CLASIFICACIÓN DE RESIDUOS PARA RECICLAJE



Ma. Lorena Montoya F.
Expositor

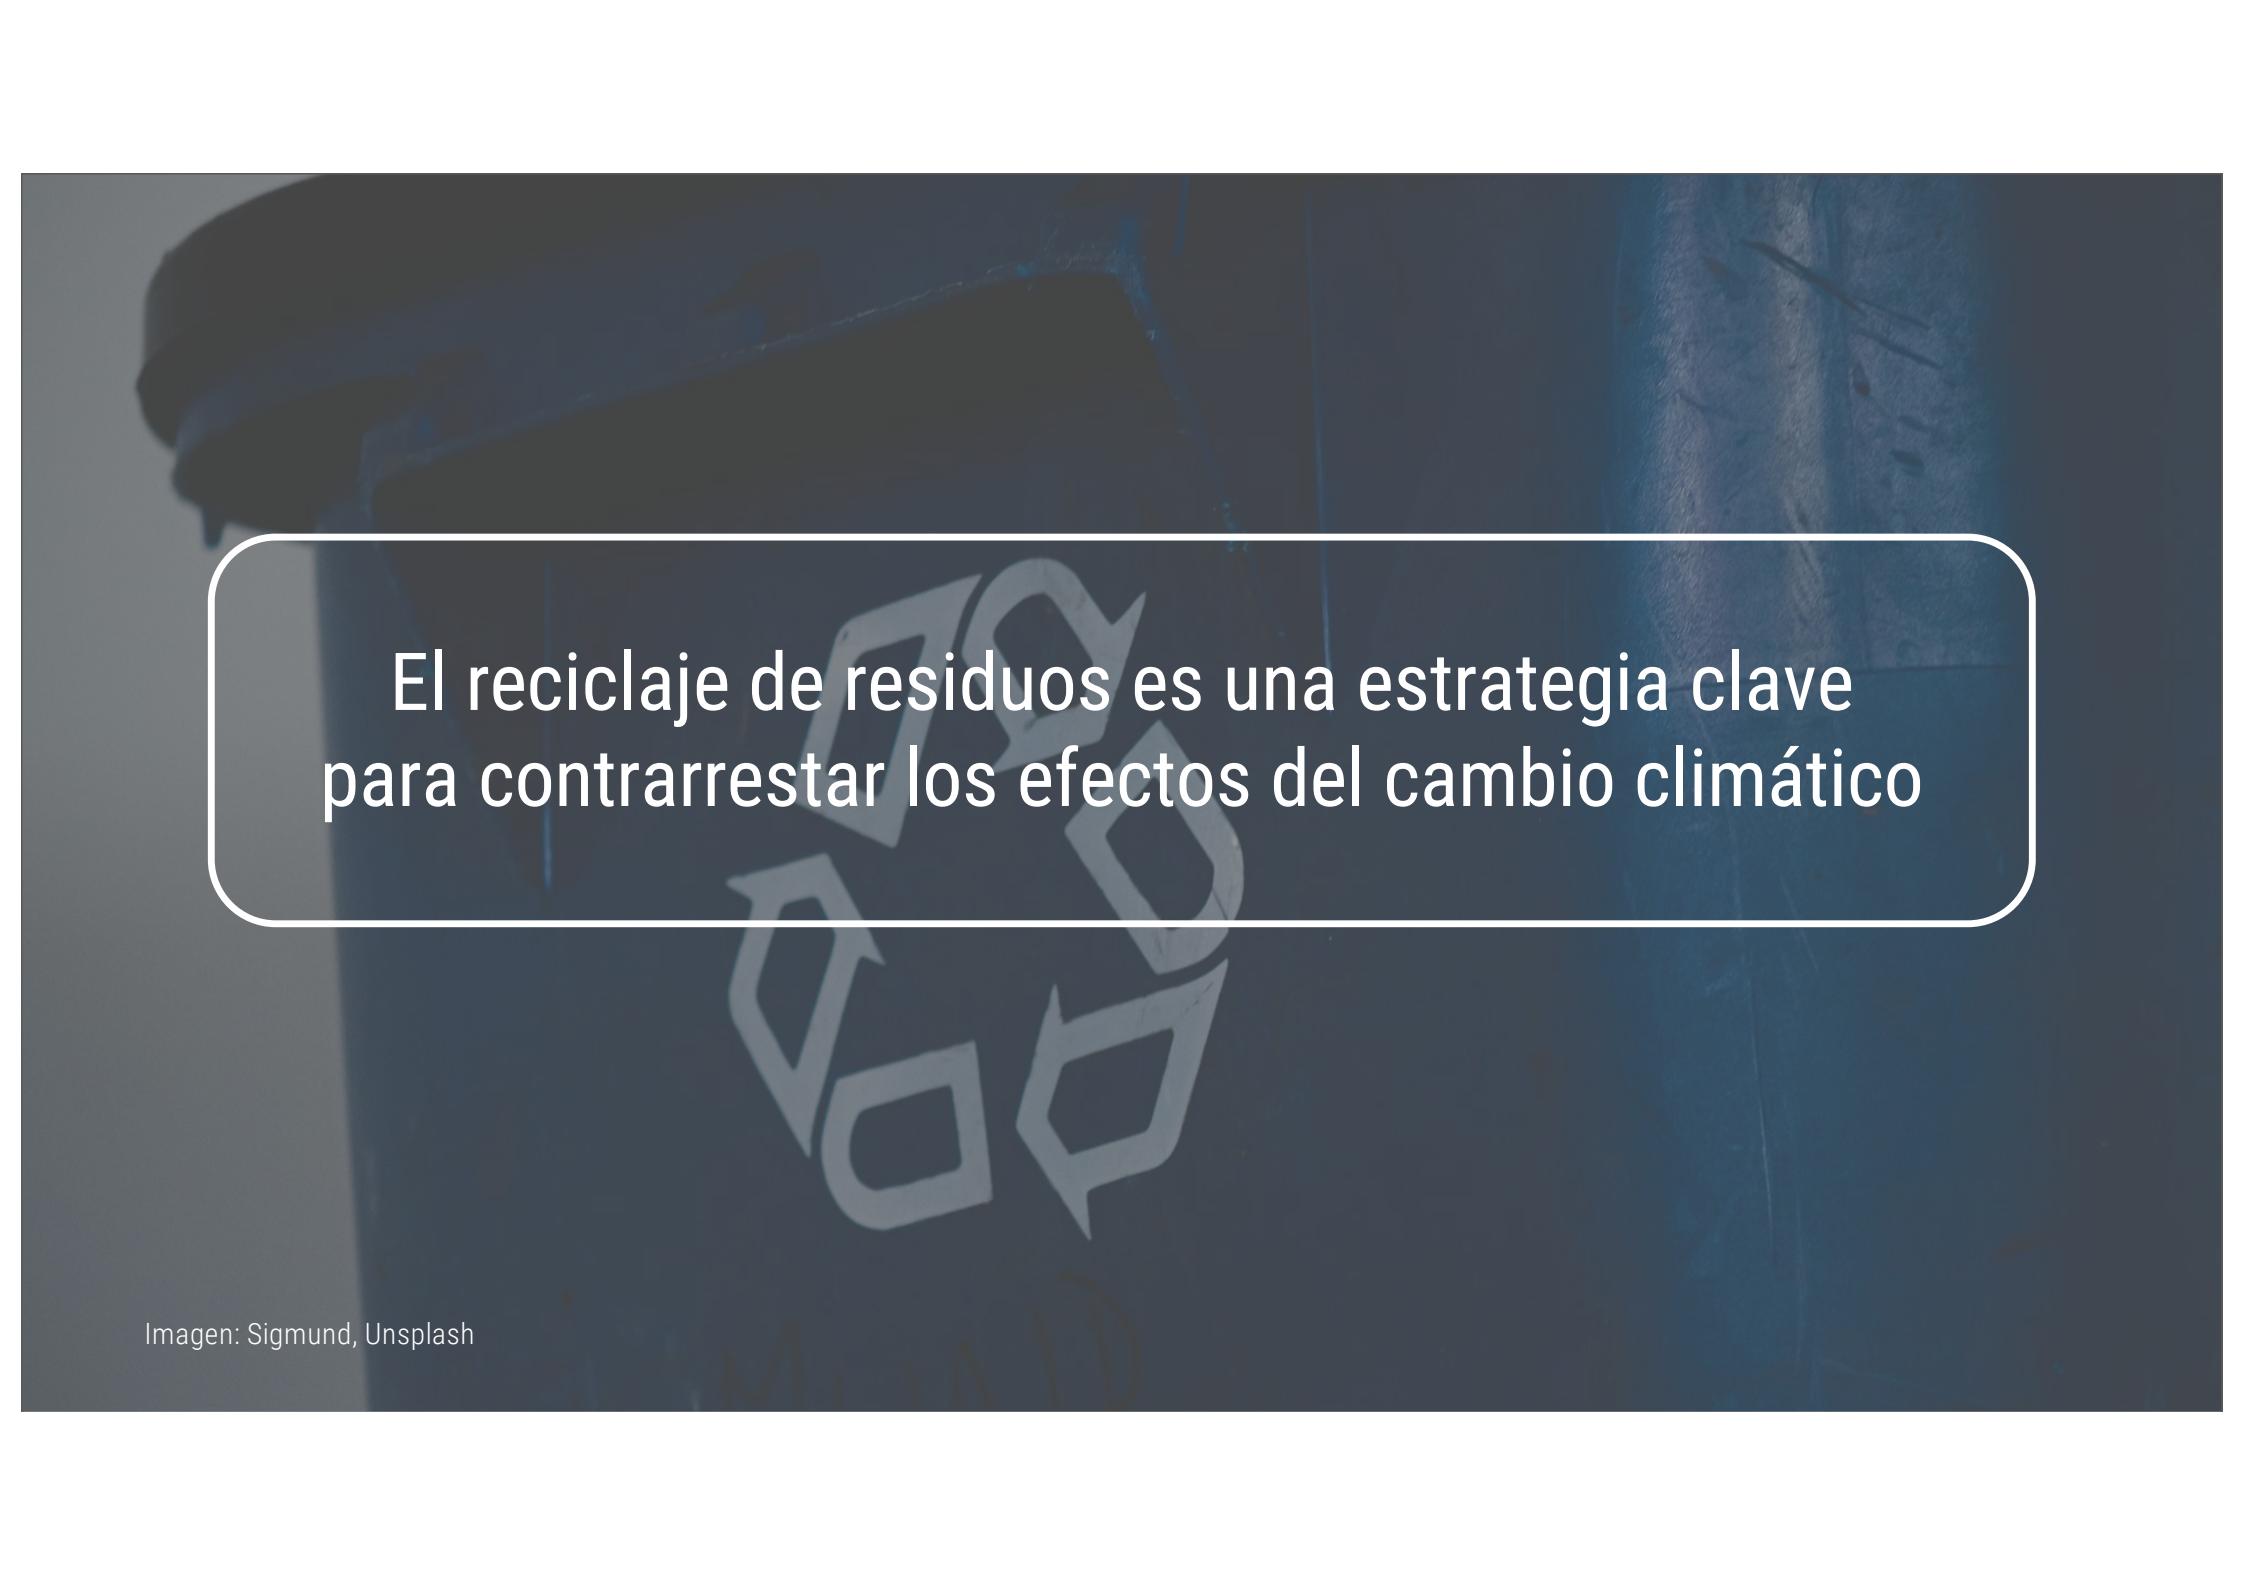


Katherine Morales
Tutor

El cambio climático

- Altas emisiones de gases de efecto invernadero
- Explotación de recursos naturales
- Alto consumo de energía

Imagen: Chris LeBoutillier, Unsplash



El reciclaje de residuos es una estrategia clave
para contrarrestar los efectos del cambio climático

Imagen: Sigmund, Unsplash

Algunas estadísticas sobre el reciclaje

- 9% de todo el desecho plástico ha sido reciclado
- 12 % de los desechos ha sido incinerado
- 79% de lo restante se encuentra en vertederos y basureros

• Fuente: ONU (2019)

Situación actual en Ecuador

Varios puntos de reciclaje ubicados en diferentes partes del país



Fuente: Gira, Biomundo Ecuador

Descripción del problema

A pesar de las guías y campañas de difusión, las personas aún **desconocen** cómo **separar** correctamente los **residuos**



Imagen: <https://www.packaginginsights.com/>

Propuesta integral

Crear una **aplicación móvil** que indique a las personas donde **depositar los residuos** y así el **reciclaje** se realice de manera **eficiente**



Propuesta integral

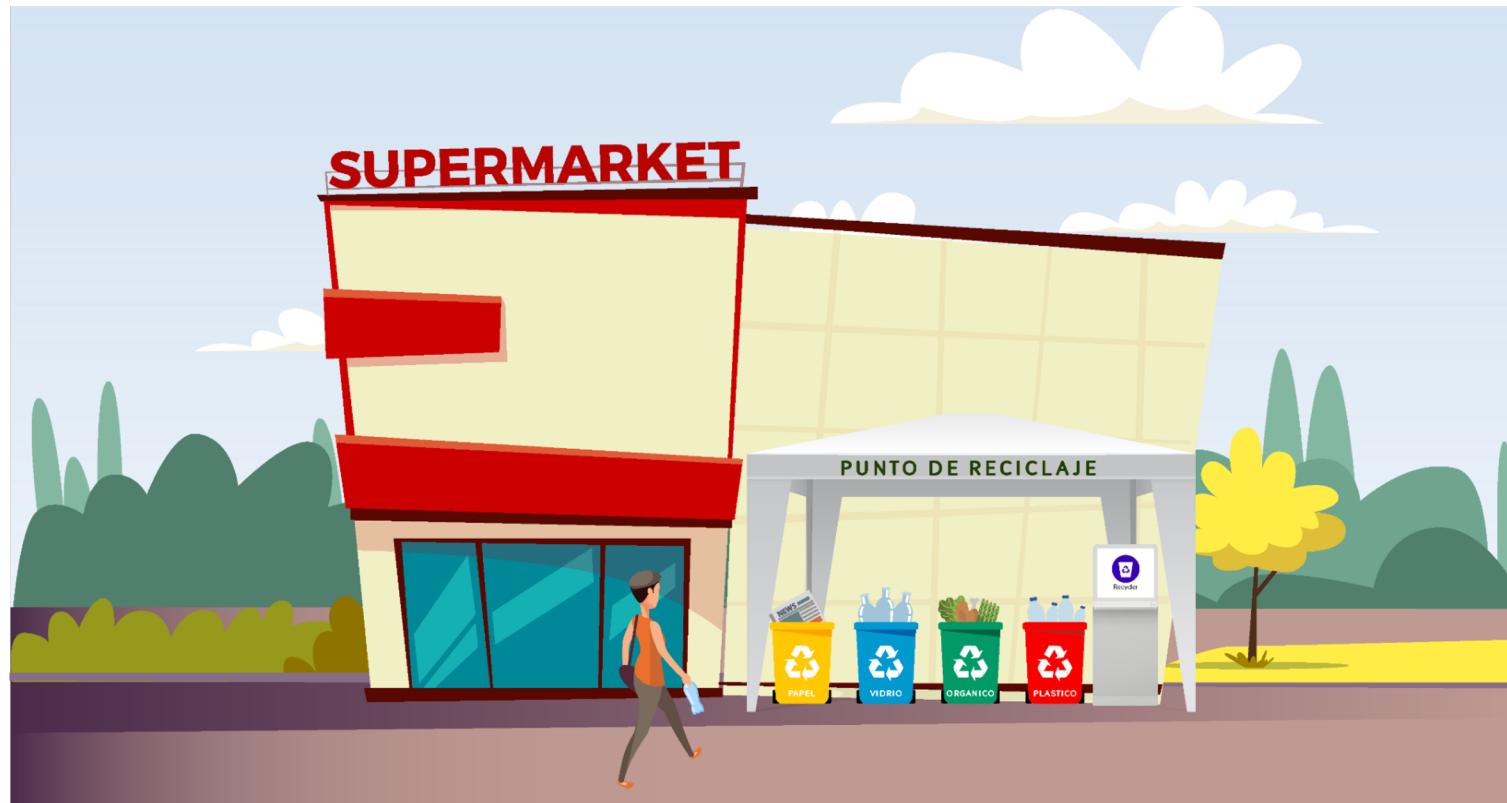


Imagen: photoroyalty, vectorpouch, macrovector_official, pch.vector, Freepik

Planteamiento del problema

Dado un **conjunto de imágenes** que representan productos diversos a desechar (residuos), se **determina** su **clase** en base a sus **características** (material, color, textura).

Propuesta de solución

El **problema** se trata de una tarea de **clasificación** de objetos en **imágenes**.

Para esto se construirá un **modelo** utilizando **redes neuronales convolucionales**.

Un vistazo al conjunto de datos

Imágenes pertenecientes a diferentes clases (Kaggle)



cardboard



paper



plastic



glass



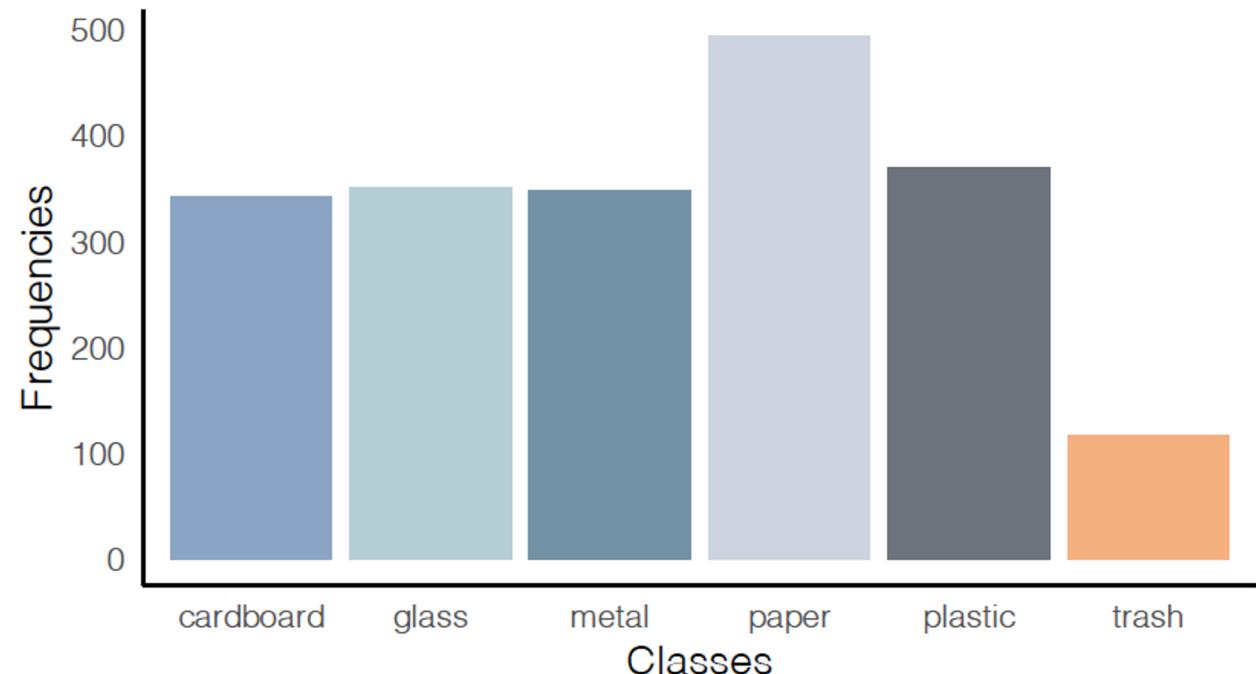
metal



trash

Análisis exploratorio de datos

Class	Train	Test
trash	117	20
glass	351	150
metal	348	62
paper	494	100
plastic	370	112
cardboard	342	61



Construcción del modelo

El modelo se construye utilizando las siguiente técnicas:

- data augmentation
- transfer learning
- fine tuning

Data augmentation

- **Mejora** el desempeño de un modelo
- **Genera** nuevas muestras en base a las muestras utilizadas durante el entrenamiento
- **Modifica** propiedades de una imagen como brillo, contraste y rotación

Transfer learning

- Uso de un **modelo previamente entrenado** (ej. ResNet50)
- Construcción de modelos utilizando los **pesos del modelo base**
- Técnica útil para **conjuntos de datos pequeños**
- **Ahorro** de **recursos** de computación y tiempo

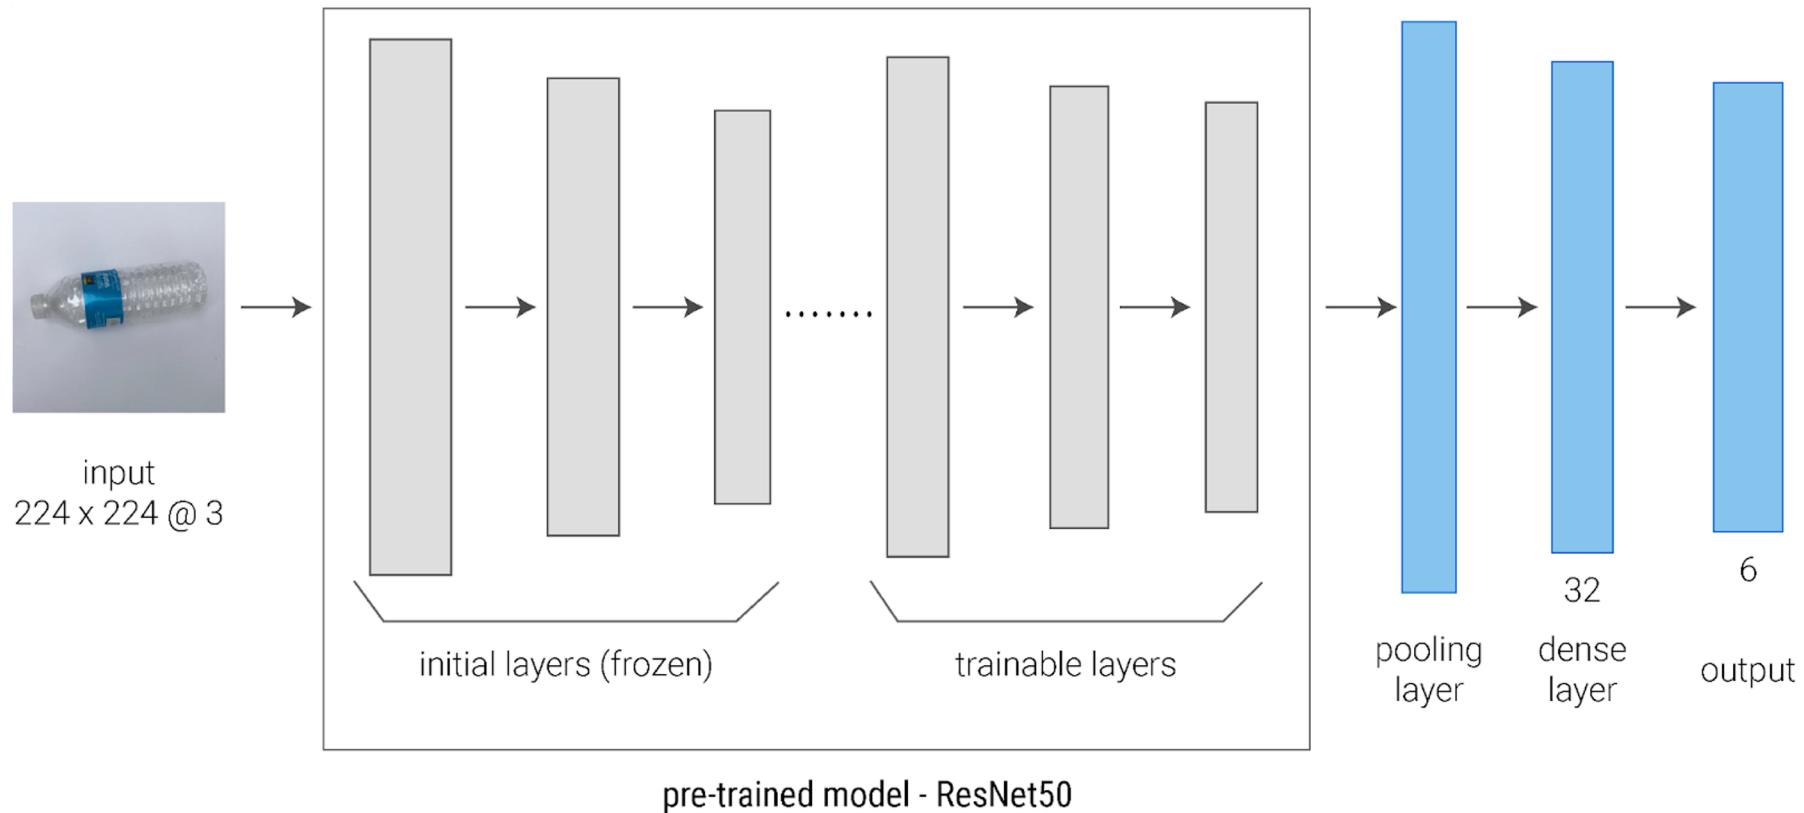
Fine tuning

- Re-entrenamiento de **las capas** de un **modelo pre-entrenado**
- **Aprendizaje de características** particulares de las **muestras** utilizadas en el problema a resolver

Comparación de técnicas

Model	Fine tuning	Data augmentation	Params	Trainable params	Non-trainable params	Accuracy	Loss
Arquitectura simple	—	✓	60.212	60.212	0	0.5425	1.0707
ResNet50V2_1	—	✓	23.614.126	49.326	23.564.800	0.8316	0.4795
ResNet50V2_2	✓	—	23.614.126	3.465.390	20.148.736	0.8376	0.5100
ResNet50V2_3	✓	✓	23.614.126	3.465.390	20.148.736	0.8435	0.4766

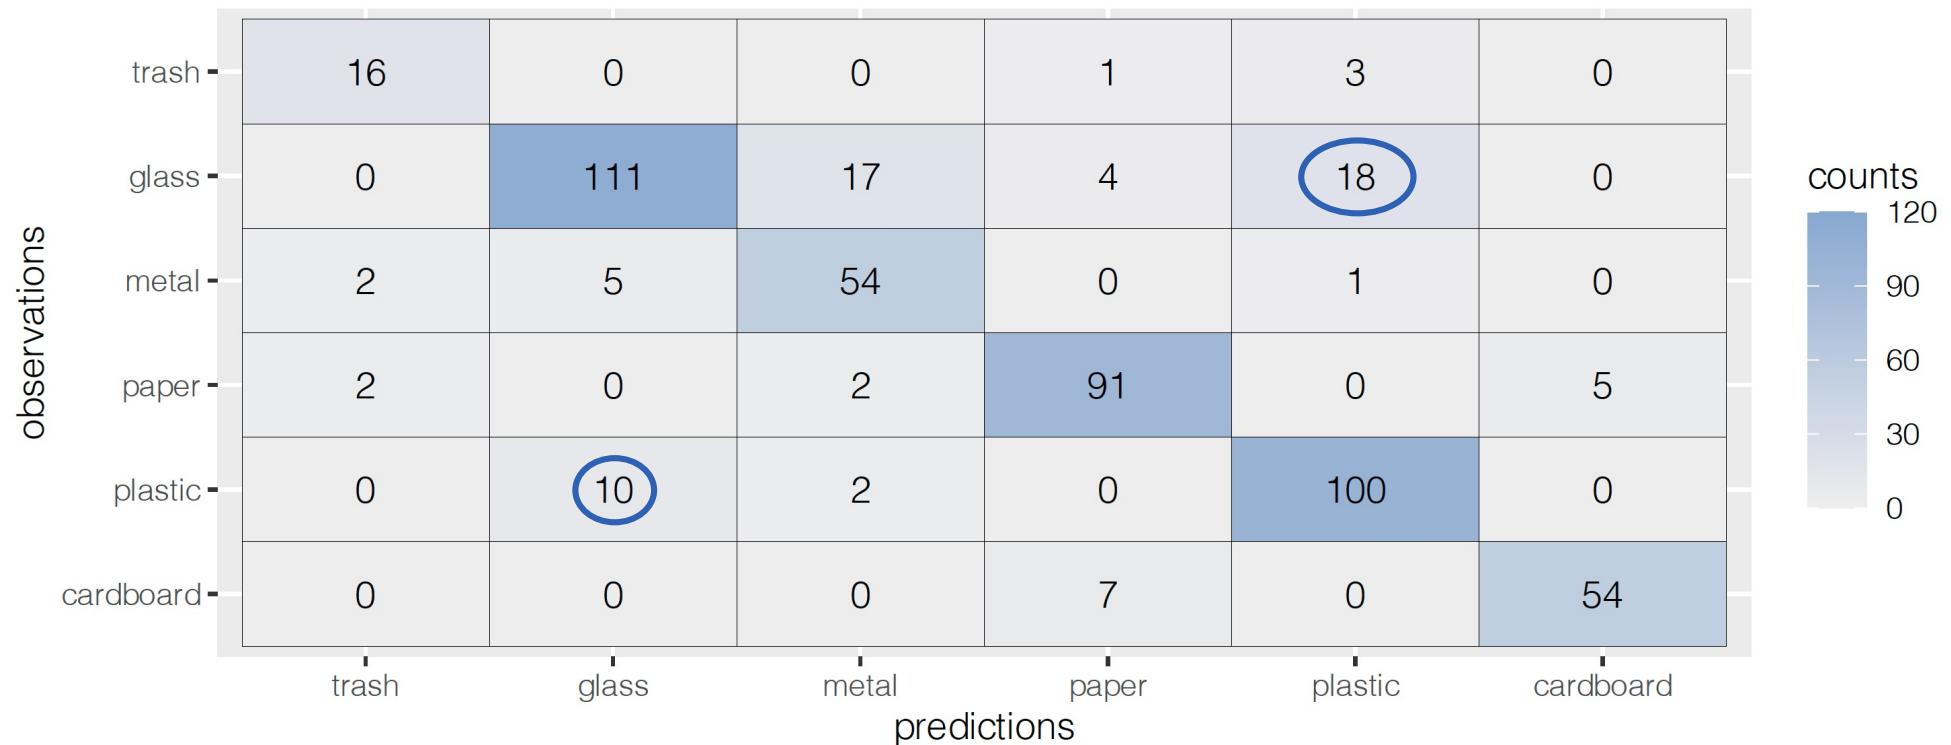
Arquitectura del modelo



Reporte de clasificación

class	precision	recall	f1-score	support
trash	0.80	0.80	0.80	20
glass	0.88	0.74	0.80	150
metal	0.72	0.87	0.79	62
paper	0.88	0.91	0.90	100
plastic	0.82	0.89	0.85	112
cardboard	0.92	0.89	0.90	61
accuracy			0.84	505
macro avg	0.84	0.85	0.84	505
weighted avg	0.85	0.84	0.84	505

Matriz de confusión



Demo



Conclusiones

- El modelo puede clasificar los ítems a reciclar con una exactitud del 84%
- La solución propuesta utiliza técnicas como data augmentation, transfer learning y fine tuning las cuales permiten obtener mejores resultados en el entrenamiento del modelo
- El uso de técnicas de regularización como las capas Dropout y L2 fue útil para reducir el sobreajuste en el modelo